

DETECÇÃO DE REVIEWS FALSAS/SINTÉTICAS EM PORTUGUÊS BRASILEIRO USANDO CNN 1D

Estudante: Randerson Sousa de Sá Nunes

Professor: Prof. Dr. Rafael Torres Anchieta

Disciplina: Aprendizado Profundo

Data: Julho de 2026

Repositório do projeto:

<<https://github.com/Altaeir-13/Indago-PT-Detecting-Synthetic-Reviews-in-Brazilian-Portuguese>>

Julho de 2026

1 Introdução

As avaliações publicadas em plataformas de comércio eletrônico exercem influência direta sobre a confiança dos consumidores, a reputação de lojas e a decisão de compra. Nesse contexto, a presença de avaliações artificiais, enganosas ou sintéticas pode comprometer a percepção pública sobre produtos e serviços. Este trabalho investiga um recorte específico desse problema: a classificação textual de avaliações individuais em português brasileiro como genuínas ou falsas/sintéticas.

A tarefa de aprendizado abordada é uma classificação binária supervisionada. A entrada do sistema é o texto de uma avaliação e a saída é um rótulo numérico, em que 0 representa uma avaliação falsa/sintética e 1 representa uma avaliação genuína. O modelo principal utilizado é uma rede neural convolucional unidimensional, implementada em PyTorch, comparada com dois modelos de referência baseados em TF-IDF: Regressão Logística e SVM Linear.

A escolha da CNN 1D é motivada pela capacidade desse tipo de arquitetura de capturar padrões locais em sequências textuais, como combinações curtas de palavras e expressões recorrentes. Trata-se de uma arquitetura adequada para demonstrar um pipeline completo de aprendizado profundo, mantendo menor complexidade computacional em comparação com modelos contextuais pré-treinados, como BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020).

2 Apresentação do Dataset

O conjunto de dados utilizado neste trabalho foi o *Fake Reviews PT-BR Dataset*, disponibilizado publicamente por Borges et al. (2025) e por seu repositório de dados (BORGES, 2025). Esse corpus foi construído a partir de avaliações genuínas extraídas da base pública *Brazilian E-Commerce Public Dataset by Olist* (SIONEK, 2018) e de avaliações falsas/sintéticas geradas por GPT-2 em português brasileiro. O dataset utilizado no experimento contém avaliações textuais, categorias de produtos e rótulos binários associados à distinção entre reviews genuínas e falsas/sintéticas.

O repositório público do *Fake Reviews PT-BR Dataset* está disponível em <<https://github.com/cristianomg10/fake-reviews-ptbr-dataset>>. A base original Olist está disponível em <<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>>. No experimento, foi utilizado o arquivo `true_fake_dataset_top15.csv`, contendo as colunas descritas na Tabela 1.

Tabela 1: Campos do dataset utilizado

Campo lógico	Nome da coluna	Descrição
Texto da avaliação	<code>review_comment_message</code>	Conteúdo textual da review
Categoria	<code>product_category_name</code>	Categoria do produto
Rótulo	<code>label</code>	0 para falsa/sintética; 1 para genuína

Após a etapa de limpeza mínima, o conjunto de dados considerado no experimento totalizou 29.988 amostras. A classe 0 corresponde a avaliações falsas/sintéticas e a classe 1 corresponde a avaliações genuínas. Os dados são textos em português brasileiro, organizados em formato tabular, acompanhados por categoria de produto e rótulo supervisionado.

A entrada textual pode ser representada formalmente como:

$$X = (x_1, x_2, \dots, x_T),$$

em que T corresponde ao tamanho da sequência textual e x_t representa o token observado na posição t . Antes de ser processado pela rede neural, o texto é tokenizado, truncado ou preenchido por padding e convertido em índices de vocabulário.

Tabela 2: Exemplos curtos de avaliações do dataset

Classe	Categoria	Exemplo curto
0 - falsa/sintética	garden_tools	“Demorou um pouco pra chegar, mas fiquei feliz com a compra...”
1 - genuína	health_beauty	“Sempre comprei neste site e nunca tive qualquer problema...”




Figura 1: Distribuição das classes no dataset após a limpeza

Fonte: elaborado pelo autor com base nos resultados do experimento.




Figura 2: Distribuição das categorias de produto no dataset

Fonte: elaborado pelo autor com base nos resultados do experimento.

3 Limitações e Tratamento do Dataset

A limpeza aplicada aos textos foi propositalmente mínima, com o objetivo de preservar sinais linguísticos potencialmente úteis para a classificação. Foram removidas avaliações vazias, e foram normalizados espaços consecutivos e quebras de linha. Não foi realizada remoção agressiva de pontuação, acentos ou marcas lexicais, pois tais elementos podem contribuir para a distinção entre os padrões textuais das classes.

A análise exploratória indicou ausência de valores nulos nas colunas canônicas após o carregamento, mas identificou 683 linhas duplicadas e 1.537 textos duplicados. Também se observou que as avaliações são relativamente curtas, com média de 82,95 caracteres e 13,98 tokens por review, além de mediana de 15 tokens.

A análise exploratória identificou duplicatas no conjunto de dados. Como o protocolo principal manteve o dataset após a limpeza mínima de textos vazios e normalização de espaços, a presença de textos duplicados pode representar uma ameaça à validade experimental, pois exemplos idênticos ou muito semelhantes podem aparecer em subconjuntos distintos de treino, validação e teste. Assim, os resultados devem ser interpretados com cautela. Como trabalho futuro, recomenda-se executar uma avaliação adicional com deduplicação antes do split, a fim de medir o impacto dessa decisão sobre as métricas.

A principal limitação conceitual do dataset está relacionada à natureza da classe falsa. Essa classe é sintética e operacional, pois foi gerada por GPT-2, e não representa necessariamente fraude humana comprovada. Além disso, o conjunto de dados não contém usuário, data, rating, produto específico ou relações entre contas. Portanto, este trabalho não realiza detecção completa de astroturfing, limitando-se à classificação de avaliações individuais.




Figura 3: Distribuição do tamanho das avaliações em tokens
 Fonte: elaborado pelo autor com base nos resultados do experimento.




Figura 4: Distribuição do tamanho das avaliações por classe
 Fonte: elaborado pelo autor com base nos resultados do experimento.

4 Trabalhos Relacionados

Borges et al. (2025) apresentam um benchmark de algoritmos de aprendizado de máquina para detecção de fake reviews em português brasileiro. Esse trabalho é diretamente relacionado ao presente estudo por tratar do mesmo domínio e por disponibilizar uma base pública adequada à investigação de avaliações falsas/sintéticas.

Kim (2014) propôs o uso de redes neurais convolucionais para classificação de sentenças, demonstrando que filtros convolucionais aplicados sobre embeddings podem capturar padrões discriminativos em texto. Essa referência fundamenta a escolha da CNN 1D como arquitetura principal deste trabalho.

Souza, Nogueira e Lotufo (2020) introduziram o BERTimbau, um modelo contextual pré-treinado para português brasileiro. Embora modelos baseados em BERT sejam relevantes para trabalhos futuros, eles não foram implementados neste experimento, pois o objetivo da avaliação foi treinar e analisar diretamente uma CNN 1D. Devlin et al. (2019) e Goodfellow, Bengio e Courville (2016) também são referências importantes para contextualizar modelos Transformer e fundamentos de aprendizado profundo. As bibliotecas utilizadas no experimento dialogam com ferramentas consolidadas de aprendizado de máquina e deep learning, como scikit-learn (PEDREGOSA et al., 2011) e PyTorch (PASZKE et al., 2019).

5 Método Implementado

O método implementado segue um pipeline textual composto pelas seguintes etapas: texto da avaliação, tokenização, padding ou truncamento, embedding treinável, convolução unidimensional, função de ativação ReLU, Global Max Pooling, dropout, camada linear e saída binária. A camada de embedding converte tokens discretos em vetores densos. A convolução unidimensional aplica filtros locais sobre a sequência, buscando padrões curtos de palavras. A função ReLU introduz não linearidade ao modelo, enquanto o Global Max Pooling seleciona os sinais mais intensos detectados pelos filtros.

O dropout foi utilizado como mecanismo de regularização para reduzir overfitting. A camada linear final gera um logit, que é usado diretamente pela função `BCEWithLogitsLoss` durante o treinamento. Essa função combina a sigmoid e a entropia cruzada binária de forma numericamente estável. Na avaliação, a sigmoid é aplicada ao logit para obter a probabilidade associada à classe genuína, e a probabilidade da classe falsa/sintética é calculada de forma complementar. A otimização foi feita com Adam, e o treinamento utilizou early stopping para interromper a execução quando a validação deixava de melhorar.

Tabela 3: Arquitetura da CNN 1D implementada

Camada	Configuração	Função
Embedding	vocab_size=20000, embedding_dim=128, padding_idx=0	Representar tokens como vetores densos
Conv1D	filters=128, kernel_size=5	Capturar padrões locais da sequência textual
ReLU	–	Introduzir não linearidade
Global Max Pooling	–	Selecionar ativações mais relevantes
Dropout	p=0.5	Reduzir overfitting
Linear	128 -> 1	Gerar logit da classificação binária
Sigmoid na avaliação	–	Converter logit em probabilidade

No método `forward`, a sequência de índices passa inicialmente pela camada de embedding, produzindo uma matriz com um vetor denso por token. Em seguida, essa matriz é transposta para o formato esperado pela convolução unidimensional, com os canais correspondendo às dimensões do embedding. A convolução e a ReLU produzem mapas de ativação ao longo da sequência; o Global Max Pooling seleciona, para cada filtro, a ativação máxima observada. O vetor resultante passa pelo dropout e pela camada linear, que retorna um único logit por avaliação.

O Trecho 1 apresenta a definição das principais camadas da CNN 1D, agora consolidada em `notebooks/01_experimento_fake_reviews.ipynb`.

Listing 1: Definição das principais camadas da CNN 1D

```
self.embedding = nn.Embedding(vocab_size, embedding_dim, padding_idx=0)
self.conv = nn.Conv1d(
    in_channels=embedding_dim,
    out_channels=filters,
    kernel_size=kernel_size,
)
self.relu = nn.ReLU()
self.dropout = nn.Dropout(dropout)
self.classifier = nn.Linear(filters, 1)
```

6 Configuração Experimental

O experimento foi desenvolvido em Python. A implementação da CNN 1D foi realizada com PyTorch, enquanto os modelos de referência foram treinados com scikit-learn. As bibliotecas

pandas e numpy foram utilizadas para manipulação dos dados, e matplotlib e seaborn foram empregadas na geração dos gráficos.

O código-fonte, as instruções de reprodução e a descrição das dependências estão disponíveis no repositório do projeto e no arquivo `README.md`. A entrega inclui o relatório em PDF, o código-fonte no GitHub, o README com instruções, os slides da apresentação e a referência ao dataset utilizado. O repositório do projeto está disponível em <<https://github.com/Altaeir-13/Indago-PT-Detecting-Synthetic-Reviews-in-Brazilian-Portuguese>>. A reprodução completa está documentada no `README.md`, incluindo instalação das dependências, posicionamento do dataset, execução do experimento, smoke test e descrição dos arquivos gerados em `outputs/`.

A divisão dos dados foi estratificada em treino, validação e teste, nas proporções de 70%, 15% e 15%, respectivamente, com `random_state` igual a 42. Os modelos avaliados foram TF-IDF com Regressão Logística, TF-IDF com SVM Linear e CNN 1D em PyTorch. As métricas foram calculadas no conjunto de teste.

6.1 Ambiente de execução

Tabela 4: Ambiente de execução registrado

Item	Valor
Sistema operacional	Windows-11-10.0.26200-SP0
Python	3.14.5
PyTorch	2.11.0+cu128
scikit-learn	1.9.0
pandas	3.0.3
numpy	2.4.6
matplotlib	3.10.9
seaborn	0.13.2
GPU detectada via CUDA	Não
Modelo da GPU	Não aplicável
<code>torch.cuda.is_available()</code>	False
Dispositivo utilizado no treinamento	cpu

Tabela 5: Hiperparâmetros principais da CNN 1D

Parâmetro	Valor
vocab_size	20000
max_len	128
embedding_dim	128
filters	128
kernel_size	5
dropout	0.5
lr	0.001
batch_size	64
epochs	30
patience	4
loss	BCEWithLogitsLoss
optimizer	Adam
random_state	42

Neste experimento, foi adotada uma configuração única de hiperparâmetros, definida com base em valores usuais para modelos CNN 1D em classificação textual e na viabilidade computacional da avaliação. O melhor checkpoint da CNN foi selecionado com base na menor perda de validação, por meio de early stopping.

Tabela 6: Modelos avaliados no experimento

Modelo	Representação	Finalidade
TF-IDF + Regressão Logística	TF-IDF	Baseline linear probabilístico
TF-IDF + SVM Linear	TF-IDF	Baseline linear de margem
CNN 1D PyTorch	Tokens e embedding treinável	Modelo principal de deep learning

Foram utilizadas as seguintes métricas: acurácia, precisão para a classe falsa/sintética, recall para a classe falsa/sintética, F1-score para a classe falsa/sintética, F1 macro, AUC-ROC orientada para a classe 0 e matriz de confusão. A classe de interesse foi definida como label 0, pois representa a avaliação falsa/sintética.

7 Resultados

A Tabela 7 apresenta os resultados reais do experimento no conjunto de teste. A CNN 1D em PyTorch obteve o melhor desempenho geral, superando os dois modelos de referência baseados em TF-IDF.

Tabela 7: Resultados quantitativos no conjunto de teste

Modelo	Accuracy	Precision 0	Recall 0	F1 0	F1 macro	AUC-ROC 0
TF-IDF + Regressão Logística	0.881085	0.867553	0.899556	0.883264	0.881043	0.949981
TF-IDF + SVM Linear	0.894421	0.886037	0.905333	0.895581	0.894408	0.959195
CNN 1D PyTorch	0.958880	0.965719	0.951556	0.958585	0.958878	0.990750

A CNN 1D atingiu 0,958880 de acurácia, 0,958585 de F1-score para a classe falsa/sintética, 0,958878 de F1 macro e 0,990750 de AUC-ROC orientada para a classe 0. Entre os baselines, o SVM Linear apresentou desempenho superior ao da Regressão Logística.




Figura 5: Curva de perda da CNN 1D durante o treinamento

Fonte: elaborado pelo autor com base nos resultados do experimento.




Figura 6: Curva de acurácia da CNN 1D durante o treinamento

Fonte: elaborado pelo autor com base nos resultados do experimento.




Figura 7: Matriz de confusão da CNN 1D no conjunto de teste

Fonte: elaborado pelo autor com base nos resultados do experimento.

8 Análise e Discussão

A CNN 1D apresentou o melhor desempenho geral do experimento. Em comparação com o SVM Linear, a CNN obteve ganho aproximado de 6,4 pontos percentuais de acurácia. Esse resultado sugere que o uso de embeddings treináveis e filtros convolucionais foi eficaz para capturar padrões locais relevantes nas avaliações textuais.

O SVM Linear foi o baseline clássico mais forte, indicando que representações TF-IDF continuam competitivas em tarefas de classificação textual. A Regressão Logística também apresentou desempenho consistente, mas inferior ao SVM Linear e à CNN 1D.

A AUC-ROC elevada da CNN, aproximadamente 99,08%, indica boa separação entre reviews sintéticas e genuínas no conjunto de teste. O F1 macro da CNN foi aproximadamente 95,89%, sugerindo desempenho equilibrado entre as classes. As curvas de treinamento e validação indicam que o modelo aprendeu padrões relevantes do conjunto de treino sem apresentar sinais fortes de underfitting. A menor perda de validação ocorreu na época 7; depois disso, a perda de treino continuou diminuindo, enquanto a perda de validação oscilou e aumentou levemente. Essa diferença sugere possibilidade de overfitting leve, controlado parcialmente pelo uso de dropout e early stopping. O treinamento foi encerrado na época 11, após quatro épocas sem melhora suficiente na perda de validação, e o melhor checkpoint foi escolhido com base na perda de validação. A matriz de confusão da CNN reforça a interpretação de que o modelo apresentou desempenho equilibrado entre as classes.

Apesar dos resultados positivos, a interpretação deve ser cautelosa. A classe falsa foi gerada por GPT-2, o que significa que o modelo pode ter aprendido padrões específicos do gerador ou do processo de construção do dataset. Assim, os resultados não devem ser interpretados como detecção de fraude humana real ou de astroturfing completo.




Figura 8: Matriz de confusão do baseline TF-IDF + Regressão Logística

Fonte: elaborado pelo autor com base nos resultados do experimento.




Figura 9: Matriz de confusão do baseline TF-IDF + SVM Linear

Fonte: elaborado pelo autor com base nos resultados do experimento.

9 Análise Qualitativa de Erros

A análise qualitativa de erros foi realizada a partir das predições da CNN 1D no conjunto de teste. Falsos positivos correspondem a avaliações genuínas classificadas como falsas/sintéticas. Falsos negativos correspondem a avaliações falsas/sintéticas classificadas como genuínas.

Tabela 8: Exemplos curtos de erros da CNN 1D

Tipo de erro	Interpretação	Exemplo curto
Falso positivo	Genuína predita como falsa/sintética	“Ainda é cedo para avaliar o produto.”
Falso negativo	Falsa/sintética predita como genuína	“Não gostei dos travesseiros... prazo de entrega é muito longo...”

Esses casos sugerem que avaliações muito curtas, genéricas, padronizadas ou com poucos detalhes concretos podem ficar próximas da fronteira de decisão do modelo. Também é possível que alguns textos sintéticos imitem padrões reais das avaliações da Olist, dificultando a separação exclusivamente com base em características textuais.

O pipeline atual salva os exemplos incorretamente classificados em `<outputs/tables/cnn_error_analysis.csv>`. A inclusão sistemática de exemplos corretamente classificados é uma melhoria futura de documentação.

10 Comparação com Trabalhos Relacionados

A comparação com a literatura deve considerar que os protocolos, conjuntos de dados, métricas e objetivos não são idênticos. Ainda assim, a Tabela 9 posiciona o presente trabalho em relação a referências relevantes da área.

Quando a métrica não é diretamente comparável ou não foi extraída do material consultado, a comparação é feita de forma qualitativa.

Tabela 9: Comparação qualitativa com trabalhos relacionados

Trabalho	Dataset	Modelo	Métrica principal	Resultado	Relação com este trabalho
Borges et al. (2025)	Fake Reviews PT-BR	Modelos clássicos e contextuais	Benchmark	Métrica não extraída do material local consultado	Referência direta de domínio e dataset
Kim (2014)	Sentenças em inglês	CNN para texto	Acurácia	Não comparável diretamente a este dataset	Referência arquitetural para CNN em texto
Souza, No-gueira e Lotufo (2020)	Corpora em português	BERTimbau	Modelo pré-treinado	Não é resultado neste dataset	Referência contextual para português brasileiro e extensão futura
Este trabalho	Fake Reviews PT-BR	CNN 1D PyTorch	F1 macro e AUC-ROC	F1 macro 0,958878; AUC 0,990750	Implementação principal avaliada neste relatório

11 Conclusão

Este trabalho apresentou um experimento completo para classificação de reviews falsas/sintéticas em português brasileiro usando uma CNN 1D em PyTorch. O pipeline incluiu carregamento do dataset, limpeza mínima, análise exploratória, divisão estratificada, treinamento de baselines, treinamento do modelo neural, avaliação quantitativa e análise qualitativa de erros.

A CNN 1D superou os baselines avaliados, atingindo 0,958880 de acurácia e 0,958878 de F1 macro. Esses resultados indicam que uma arquitetura convolucional simples pode ser competitiva para a classificação textual neste dataset. Contudo, as conclusões devem permanecer restritas ao escopo do experimento: o modelo distingue avaliações genuínas de avaliações sintéticas geradas no dataset, mas não comprova detecção de fraude humana nem de astroturfing completo.

Como continuidade, o projeto pode ser reaproveitado em um Trabalho de Conclusão de Curso como pipeline experimental reutilizável, como etapa intermediária entre modelos TF-IDF e BERTimbau, e como base para discussão de ameaças à validade. Trabalhos futuros podem incluir comparação com BERTimbau, CNN multi-kernel, validação cruzada, deduplicação antes da divisão dos dados e uso de metadados comportamentais ou grafos quando houver dados apropriados.

12 Declaração de Uso de IA Generativa

Ferramentas de IA generativa, incluindo ChatGPT/Codex, foram utilizadas como apoio na organização textual do relatório, revisão de clareza, estruturação de trechos explicativos e auxílio na organização do código. Os experimentos, métricas, tabelas e gráficos apresentados

foram obtidos por execução local do código-fonte do projeto. A correção das informações foi verificada por inspeção do código, conferência dos arquivos gerados em `outputs/`, comparação entre tabelas de métricas e saídas do experimento, além de revisão manual do texto final. O autor assume responsabilidade pela implementação, análise, resultados e conteúdo final apresentado.

Referências

- BORGES, E. C. R. *Fake Reviews PT-BR Dataset*. GitHub, 2025. Disponível em: <<https://github.com/cristianomg10/fake-reviews-ptbr-dataset>>. Acesso em: 2 jul. 2026.
- BORGES, E. C. R. et al. Benchmarking machine learning algorithms in fake reviews detection in brazilian portuguese. *Revista Brasileira de Computação Aplicada*, 2025.
- DEVLIN, J. et al. Bert: Pre-training of deep bidirectional transformers for language understanding. In: *Proceedings of NAACL-HLT*. [S.l.: s.n.], 2019.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. [S.l.]: MIT Press, 2016.
- KIM, Y. Convolutional neural networks for sentence classification. In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*. [S.l.: s.n.], 2014. p. 1746–1751.
- PASZKE, A. et al. Pytorch: An imperative style, high-performance deep learning library. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2019.
- PEDREGOSA, F. et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- SIONEK, A. *Brazilian E-Commerce Public Dataset by Olist*. Kaggle, 2018. Disponível em: <<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>>. Acesso em: 2 jul. 2026.
- SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. Bertimbau: Pretrained bert models for brazilian portuguese. In: *Brazilian Conference on Intelligent Systems*. [S.l.: s.n.], 2020.