

# Detecção de reviews falsas/sintéticas em português brasileiro

CNN 1D em PyTorch para classificação textual supervisionada

**Randerson Sousa de Sá Nunes**

Prof. Dr. Rafael Torres Anchieta

Disciplina: Aprendizado Profundo • Julho de 2026

**29.988**

amostras no dataset

**96,13%**

F1 macro da CNN 1D

*Dataset: Fake Reviews PT-BR • Modelo principal: CNN 1D • Baselines: TF-IDF + Reg. Logística / SVM Linear*

# O que o modelo precisa resolver?

---

**Tarefa** Classificação binária supervisionada: uma review é genuína (1) ou falsa/sintética (0).

---

**Relevância** Reviews influenciam confiança do consumidor, reputação de lojas e decisão de compra.

---

**Modelo escolhido** CNN 1D: captura padrões locais de palavras com custo computacional menor que Transformers.

---

**Escopo real** O trabalho não detecta astroturfing completo; analisa somente o texto da review.

---

**Limitação conceitual** A classe falsa é sintética, gerada por GPT-2, não fraude humana comprovada.

---

# Fake Reviews PT-BR Dataset

**29.988**amostras após  
limpeza**2**

classes

**15**


categorias

**1.537**

textos duplicados


Base pública derivada de reviews genúnas da Olist e textos sintéticos gerados por GPT-2. Entrada: texto + categoria + label;  $X = (x_1, x_2, \dots, x_T)$ , com tokenização, padding/truncamento e embedding treinável.

*Ameaça à validade: duplicatas antes do split podem inflar métricas por vazamento de informação.*




Distribuição por categoria de produto


# Distribuição das classes e tamanho das reviews




Distribuição das classes



Tamanho em caracteres



Tamanho em tokens



Tokens por classe

- Classes balanceadas (~15.000 amostras cada), com média de 82,95 caracteres e 13,98 tokens por review.
- Mediana de 15 tokens; reviews genúnas (classe 1) apresentam maior dispersão de tamanho que as sintéticas (classe 0).

# Entre benchmark clássico e deep learning simples

## Borges et al. (2025)

- Benchmark em fake reviews PT-BR; melhor resultado com Reg. Logística + BERTimbau (96,55% acc / 96,54% F1).

## Kim (2014)

- Base conceitual para CNNs em classificação de sentenças; fundamenta o uso de filtros convolucionais em texto.

## Souza, Nogueira e Lotufo (2020)

- BERTimbau, modelo contextual pré-treinado em português — referência para trabalhos futuros.


## Deshai e Rao (2023)

- CNN + Adaptive PSO em 5 datasets internacionais de fake reviews; 99,4% de acurácia.

## Vidanagama, Silva e Karunananda (2020)

- CNN simples atingiu 92,7% (Yelp) e 97,3% (Amazon), evidenciando robustez da arquitetura.

# CNN 1D implementada



- Perda: BCEWithLogitsLoss para classificação binária com estabilidade numérica.
- Regularização: dropout  $p=0,5$  e early stopping pela menor perda de validação.
- Motivação: padrões locais de palavras com menor custo computacional que Transformers.
- Camadas fixas (ReLU, MaxPooling) vs. Sigmoid aplicada apenas na inferência para converter logit em probabilidade.

# Como o experimento foi conduzido

## Ambiente

- Python 3.14.5
- PyTorch 2.11.0 + CUDA 12.8
- GPU: NVIDIA RTX 3060 Ti
- scikit-learn, pandas, numpy
- matplotlib, seaborn

## Divisão dos dados

- Treino 70% / Validação 15% / Teste 15%
- Divisão estratificada, random\_state = 13

## Hiperparâmetros da CNN 1D

|                         |                 |
|-------------------------|-----------------|
| vocab_size              | 30000           |
| max_len                 | 256             |
| embedding_dim           | 128             |
| kernel_size             | 7               |
| dropout                 | 0,5             |
| optimizer               | Adam (lr=0,001) |
| batch_size              | 128             |
| epochs (max / patience) | 50 / 3          |

# A CNN 1D foi o melhor modelo no teste

96,13%

acurácia CNN 1D



99,14%

AUC-ROC classe 0

+6,4 p.p.

acurácia vs. SVM Linear

| Modelo         | Acc    | Prec. 0 | Recall 0 | F1 0   | F1 macro | AUC 0  |
|----------------|--------|---------|----------|--------|----------|--------|
| Reg. Logística | 0,8771 | 0,8558  | 0,9071   | 0,8807 | 0,8770   | 0,9472 |
| SVM Linear     | 0,8973 | 0,8788  | 0,9218   | 0,8998 | 0,8972   | 0,9610 |
| CNN 1D         | 0,9613 | 0,9735  | 0,9484   | 0,9608 | 0,9613   | 0,9914 |




## Leitura das curvas


Overfitting leve após a época 5; early stopping encerra o treino na época 8, com o melhor checkpoint escolhido pela menor perda de validação.




# Onde os modelos ainda erram?



CNN 1D



SVM Linear



Regressão Logística

## Falso positivo (CNN)

Review genuína classificada como falsa. Comum em reclamações curtas ou pouco contextualizadas.

## Falso negativo (CNN)

Review sintética classificada como genuína. Ocorre quando o texto imita padrões reais.

*Leitura crítica: metadados de usuário e produto poderiam melhorar a detecção.*

# Como o resultado se posiciona na literatura?

| Trabalho                 | Dataset                              | Modelo                | Resultado principal              |
|--------------------------|--------------------------------------|-----------------------|----------------------------------|
| Borges et al. (2025)     | Fake Reviews PT-BR                   | Reg. Log. + BERTimbau | 96,55% acc / 96,54% F1 (10-fold) |
| Vidanagama et al. (2020) | Yelp / Amazon                        | CNN para texto        | 92,7% (Yelp) / 97,3% (Amazon)    |
| Deshai e Rao (2023)      | Ott, Amazon, Yelp, TripAdvisor, IMDb | CNN + Adaptive PSO    | 99,4% de acurácia                |
| Este trabalho            | Fake Reviews PT-BR                   | CNN 1D PyTorch        | 96,13% F1 macro / 99,14% AUC-ROC |

Observação: comparação não controlada — diferem idioma, dataset, protocolo, representação textual e métricas.

## Entregáveis e transparência do experimento

### Código-fonte

Disponível no repositório GitHub, com instruções de instalação e execução.

### README

Contém identificação, descrição do problema, dataset, modelo, ambiente e comandos de execução.

### Dataset público

Fake Reviews PT-BR, com link de acesso e documentação da fonte original (Olist + GPT-2).

### Declaração de IA

Uso de IA generativa como apoio à escrita e revisão, com conteúdo validado pelo autor.

Repositório: [github.com/Altaeir-13/Indago-PT-Detecting-Synthetic-Reviews-in-Brazilian-Portuguese](https://github.com/Altaeir-13/Indago-PT-Detecting-Synthetic-Reviews-in-Brazilian-Portuguese)

Ambiente, hiperparâmetros e seed documentados para reprodução completa do experimento.

# Uma CNN 1D simples, reprodutível e criticamente analisada

- CNN 1D teve o melhor desempenho geral (96,13% F1 macro / 99,14% AUC-ROC).
- SVM Linear foi o baseline clássico mais forte, à frente da Regressão Logística.
- Resultados válidos para reviews sintéticas geradas por GPT-2 neste dataset específico.
- Duplicatas antes do split são a principal ameaça à validade experimental.

## Trabalhos futuros

Dedupicação antes do split • Validação cruzada • CNN multi-kernel • Comparação com BERTimbau • Metadados

**Obrigado!**