

Detecção de reviews falsas/sintéticas em português brasileiro

CNN 1D em PyTorch para classificação textual supervisionada

Dataset: Fake Reviews PT-BR

Baselines: TF-IDF + modelos lineares

**CNN
1D**

Randerson Sousa de Sá Nunes
Prof. Dr. Rafael Torres Anchieta

O que o modelo precisa resolver?

Classificar uma review individual como genuína ou falsa/sintética.



Tarefa

Classificação binária supervisionada de texto.



Relevância

Reviews influenciam confiança, reputação de lojas e decisão de compra.



Modelo

CNN 1D por capturar padrões locais de palavras com custo menor que Transformers.



Escopo real

O trabalho não detecta astroturfing completo; analisa somente o texto da review.



Limitação conceitual

A classe falsa é sintética, gerada por GPT-2, não fraude humana comprovada.

Fake Reviews PT-BR Dataset

Base pública derivada de reviews genuínas da Olist e textos sintéticos.

29.988

amostras após limpeza

2

classes

15

categorias

0

ausentes

1.537

textos duplicados

CSV

texto + categoria +
label

Entrada do modelo

$X = (x_1, x_2, \dots, x_T)$
Tokenização, padding/truncamento e embedding
treinável.

Ameaça à validade

Duplicatas antes do split podem inflar métricas por
vazamento de informação.

O trabalho fica entre benchmark clássico e aprendizado profundo simples

Borges et al. (2025)

Benchmark em fake reviews PT-BR; referência direta de domínio.

Kim (2014)

Base conceitual para CNNs em classificação de sentenças.


BERTimbau

Modelo contextual em português; comparação futura.

Comparação não totalmente controlada: protocolos, splits e arquiteturas diferem.

CNN 1D implementada

Arquitetura treinada do zero com embedding treinável.



Perda

BCEWithLogitsLoss para classificação binária com estabilidade numérica.



Regularização

Dropout $p=0,5$ e early stopping pela menor perda de validação.



Motivação

Padrões locais de palavras com menor custo computacional que Transformers.

Como o experimento foi conduzido

Ambiente, divisão dos dados, hiperparâmetros e métricas.

Ambiente

Python 3.14.5
PyTorch 2.11.0 + CUDA 12.8
GPU RTX 3060 Ti

Arquitetura

vocab_size=30000
max_len=256
embedding_dim=128
kernel_size=7

Treino

Adam, lr=0,001
batch_size=128
epochs=50
patience=3

Métricas: acurácia, precisão, recall, F1 da classe falsa/sintética, F1 macro, AUC-ROC e matriz de confusão.

A CNN 1D foi o melhor modelo no teste

96,13%

F1 macro

99,14%


AUC-ROC classe 0

+6,4 p.p.

acurácia vs. SVM

Interpretação: embeddings treináveis + filtros convolucionais capturaram padrões locais que os baselines lineares não representaram tão bem.

Acurácia por modelo



Onde o modelo ainda erra?

Os erros mostram o limite de decidir apenas pelo texto isolado.

Matriz de confusão | CNN 1D

real		2134	116
		58	2191
	predito		

Falso positivo

Review genuína classificada como falsa.

Comum em reclamações curtas ou pouco contextualizadas.

Falso negativo

Review sintética classificada como genuína.

Ocorre quando o texto sintético imita padrões reais.

Leitura crítica: metadados de usuário e produto poderiam melhorar a detecção.

Como o resultado se posiciona?

A comparação é útil, mas não é controlada por diferenças de protocolo.

Trabalho	Dataset	Modelo	Resultado
Borges et al. (2025)	Fake Reviews PT-BR	Reg. Logística + BERTimbau	96,55% acc / 96,54% F1
Este trabalho	Fake Reviews PT-BR	CNN 1D PyTorch	96,13% F1 macro / 99,14% AUC



Por que não é comparação direta?

Os resultados usam protocolos, splits, representações e arquiteturas diferentes. O valor principal aqui é mostrar uma implementação própria, reproduzível e criticamente analisada.

O experimento atende ao objetivo com uma CNN 1D simples, reprodutível e analisável

- CNN 1D teve o melhor desempenho geral.
- SVM foi o baseline clássico mais forte.
- Resultados valem para reviews sintéticas do dataset.
- Duplicatas antes do split são a principal ameaça à validade.

Trabalhos futuros

Deduplicação antes do split
Validação cruzada
CNN multi-kernel
Comparação com BERTimbau
Metadados, se disponíveis

Obrigado!